

chap9_추천 시스템

추천 시스템의 개요와 배경

📌 추천 시스템을 접한 사용자 → 더 많은 추천 콘텐츠 선택 → 더 많은 데이터가 추천 시스템에 축적 → 더 정확하고 다양한 결과 얻을 수 있는 선순환 시스템 구축

추천 시스템

- 콘텐츠 기반 필터링 (Content based filtering)
- 협업 필터링 (Collaborative Filtering)
 - 최근접 이웃 (Nearest Neighbor)
 - 잠재 요인 (Latent Factor)

콘텐츠 기반 필터링 추천 시스템

: 사용자가 특정한 아이템을 매우 선호하는 경우, 그 아이템과 비슷한 콘텐츠를 가진 다른 아이템을 추천하는 방식

ex) 사용자가 특정 영화에 높은 평점을 줬다면

그 영화의 장르, 출연 배우, 감독, 영화 키워드 등의 콘텐츠와 유사한 다른 영화를 추천해주는 방식

최근접 이웃 협업 필터링

: 사용자가 아이템에 매긴 평점 정보나 상품 구매 이력과 같은 사용자 행동 양식(User Behavior)만을 기반으로 추천을 수행하는 것

주요 목표:

축적된 사용자 행동 데이터를 기반으로 사용자가 아직 평가하지 않은 아이템을 예측 평가 (Predicted Rating)하는 것

협업 필터링 기반의 추천 시스템 (최근접 이웃 방식 & 잠재 요인 방식) : 사용자-아이템 평점 행렬 데이터에만 의존해 추천을 수행함.

✅ 사용자-아이템 평점 행렬

- 행(Row): 개별 사용자

- 열(Column): 개별 아이템

→ 사용자 아이디 행, 아이템 아이디 열 위치에 해당하는 값: 평점

로우 레벨 형태의 사용자 - 아이템 평점 데이터			사용자 로우, 아이템 칼럼으로 구성된 사용자 - 아이템 평점 데이터				
User ID	Item ID	Rating					
User 1	Item 1	3					
User 1	Item 3	3					
User 2	Item 1	4					
User 2	Item 2	1					
User 3	Item 4	5					



	Item 1	Item 2	Item 3	Item 4
User 1	3		3	
User 2	4	1		
User 3				5

- 이럴 경우에는 pivot_table() 함수를 사용해 오른쪽과 같이 변경함

최근접 이웃 협업 필터링(메모리 memory 협업 필터링)

사용자 기반 (User-User)	아이템 기반 (Item-Item)
당신과 비슷한 고객들이 다음 상품도 구매했습니다.	이 상품을 선택한 다른 고객들은 다음 상품도 구매했습니다.

사용자 기반 최근접 이웃 방식

: 특정 사용자와 타 사용자 간의 유사도(Similarity)를 측정한 뒤 가장 유사도가 높은 Top-N 사용자를 추출해 그들이 선호하는 아이템을 추천하는 것

아이템 기반 최근접 이웃 방식

: 아이템이 가지는 속성과는 상관없이


사용자들이 그 아이템을 좋아하는지/싫어하는지의 평가 척도가 유사한 아이템을 추천하는 기준이 되는 알고리즘

→ 정확도가 더 높음!


잠재 요인 협업 필터링

: 사용자-아이템 평점 매트릭스 속에 숨어 있는 잠재 요인을 추출해 추천 예측을 할 수 있게 하는 기법

행렬 분해(Matrix Factorization): 대규모 다차원 행렬을 SVD와 같은 차원 감소 기법으로 분해하는 과정에서 잠재 요인 추출



이 때 행렬 분해에 의해 추출되는 '잠재 요인'이 정확히 어떤 것인지는 알 수 없지만, 가령 영화 평점 기반의 사용자-아이템 평점 행렬 데이터라면 영화가 가지는 장르별 특성 선호도로 가정할 수 있다.



행렬 분해의 이해

행렬 분해: 다차원의 매트릭스 → 저차원 매트릭스로 분해


- SVD(Singular Vector Decomposition)
- NMF(Non-Negative Matrix Factorization)

평점 행렬 R(M X N) 을 사용자 잠재 요인 행렬 P(M x K)와 아이템 잠재 요인 행렬 Q(N x K) 로 분해하여,

K차원 잠재 공간에서 평점을 예측하는 것 ⇒ 잠재 요인 기반 협업 필터링

$$R = P * Q.T$$


- R: M개의 사용자(User)행 , N개의 총 아이템(Item)열
- K: 잠재 요인의 차원 수
- Q.T: Q 매트릭스의 행과 열 값을 교환한 전치 행렬



R 행렬의 u행 사용자와 i열 아이템 위치에 있는 평점 데이터를 $r_{u,i}$ 라고 하면

$$r_{u,i} = p_u * q_i^t$$

로 유추할 수 있습니다. 여기서 p_u 는 P 행렬에서 u행 사용자의 벡터이며, q_i^t 는 Q 행렬의 i행 아이템 벡터의 전치 벡터입니다. 가령 다음 그림과 같이 R 행렬의 2행 사용자와 4열 아이템에 해당하는 $r_{2,4}$ 평점 3점은 $r_{2,4} = p_2 * q_4^t$ 입니다. 따라서 $r_{2,4}$ 예측값은 $2.14 * 1.36 + 0.08 * 0.75 = 2.97$ 로 계산할 수 있습니다.



행렬 분해는 주로 SVD 방식을 이용하지만,

SVD는 널(NaN) 값이 없는 행렬에만 적용할 수 있으므로,

이러한 경우에는 확률적 경사 하강법(Stochastic Gradient Descent, SGD)나 ALS(Alternating Least Squares) 방식을 이용해 SVD 수행

확률적 경사 하강법을 이용한 행렬 분해

: P와 Q 행렬로 계산된 예측 R 행렬 값이 실제 R 행렬 값과 가장 최소의 오류를 가질 수 있도록 반복적인 비용 함수 최적화를 통해 P와 Q를 유추해내는 것

1. P와 Q를 임의의 값을 가진 행렬로 설정한다.
2. P와 Q.T 값을 곱해 예측 R 행렬을 계산하고, 예측 R 행렬과 실제 R 행렬에 해당하는 오류 값을 계산한다.
3. 이 오류 값을 최소화할 수 있도록 P와 Q 행렬을 적절한 값으로 각각 업데이트한다.
4. 만족할 만한 오류 값을 가질 때까지 2,3번 작업을 반복하면서 P와 Q 값을 업데이트해 근사화한다.

실제 값과 예측값의 오류 최소화와 L2 규제(Regularization)를 고려한 비용 함수식은 다음과 같습니다.

$$\min \sum (r_{u,i} - p_u q_i^t)^2 + \lambda (\|q_i\|^2 + \|p_u\|^2)$$

새롭게 업데이트 되는 값:

$$\begin{aligned} p'_u &= p_u + \eta (e_{(u,i)} * q_i - \lambda * p_u) \\ q'_i &= q_i + \eta (e_{(u,i)} * p_u - \lambda * q_i) \end{aligned}$$

- p_u : P 행렬의 사용자 u행 벡터
- q_i^t : Q 행렬의 아이템 i행의 전치 벡터(transpose vector)
- $r_{u,i}$: 실제 R 행렬의 u행, i열에 위치한 값.
- $\hat{r}_{u,i}$: 예측 R 행렬의 u행, i열에 위치한 값. $p_u * q_i^t$ 로 계산
- $e_{(u,i)}$: u행, i열에 위치한 실제 행렬 값과 예측 행렬 값의 차이 오류. $r_{u,i} - \hat{r}_{u,i}$ 로 계산
- η : SGD 학습률
- λ : L2 규제(Regularization) 계수

파이썬 추천 시스템 패키지 - Surprise

Surprise 패키지의 장점

- 다양한 추천 알고리즘(사용자 또는 아이템 기반 최근접 이웃 협업 필터링, SVD, SVD++, NMF 기반의 잠재 요인 협업 필터링)을 쉽게 적용해 추천 시스템 구축 가능
- 핵심 API가 사이킷런의 핵심 API와 유사하게 작성됨.
 - `fit()`, `predict()`: 추천 데이터 학습과 예측
 - `train_test_split()`: 추천 학습 데이터 세트와 예측 데이터 세트 분리
 - `cross_validate()`, `GridSearchCV` 클래스: 추천 시스템을 위한 모델 선택, 평가, 하이퍼 파라미터 튜닝 등의 기능 제공

Reader 클래스 (Surprise 데이터 세트가 무비렌즈 데이터 형식을 따르기 때문에 이 형식이 없는 OS 파일의 경우 Reader 클래스 설정해야함)

- `line_format(string)`: 칼럼을 순서대로 나열
- `sep(char)`: 칼럼을 분리하는 분리자.
 - 디폴트: `\t`
- `rating_scale(tuple, optional)`: 평점 값의 최소 ~ 최대 평점을 설정
 - 디폴트: (1, 5)

Surprise 추천 알고리즘 클래스

- SVD: 행렬 분해를 통한 잠재 요인 협업 필터링을 위한 알고리즘
- KNNBasic: 최근접 이웃 협업 필터링을 위한 KNN 알고리즘
- BaselineOnly: 사용자 Bias와 아이템 Bias를 감안한 SGD 베이스라인 알고리즘

SVD 클래스의 입력 파라미터:

파라미터명	내용
<code>n_factors</code>	잠재 요인 K의 개수. 디폴트는 100, 커질수록 정확도가 높아질 수 있으나 과적합 문제가 발생할 수 있습니다.
<code>n_epochs</code>	SGD(Stochastic Gradient Descent) 수행 시 반복 횟수, 디폴트는 20.
<code>biased (bool)</code>	베이스라인 사용자 편향 적용 여부이며, 디폴트는 True입니다.

베이스라인 평점

: 한 개인의 성향을 반영해 아이템 평가에 편향성 요소를 반영하여 평점을 부과하는 것

$$\text{전체평균평점} + \text{사용자편향점수} + \text{아이템편향점수공식}$$

- 전체 평균 평점 = 모든 사용자 아이템에 대한 평점을 평균한 값
- 사용자 편향 점수 = 사용자별 아이템 평점 평균 값 - 전체 평균 평점
- 아이템 편향 점수 = 아이템별 평점 평균 값 - 전체 평균 평균