

chap8.6-9

토픽 모델링(Topic Modeling): 문서 집합에 숨어 있는 주제를 찾아내는 것

사람이 수행하는 토픽 모델링은 더 함축적인 의미로 문장을 요약하는 것에 반해, 머신러닝 기반의 토픽 모델은 숨겨진 주제를 효과적으로 표현할 수 있는 중심 단어를 함축적으로 추출한다.

- LSA(Latent Semantic Analysis)
- LDA(Latent Dirichlet Allocation)

문서 군집화(Document Clustering): 비슷한 텍스트 구성의 문서를 군집화하는 것

텍스트 분류 기반의 문서 분류는 사전에 결정 카테고리 값을 가진 학습 데이터 세트가 필요한데 반해, 문서 군집화는 학습 데이터 세트가 필요 없는 비지도학습 기반으로 동작한다.

문서와 문서 간 유사도 비교 - 코사인 유사도 사용.

코사인 유사도(Cosine Similarity): 두 벡터 사이의 사잇각을 구해서 얼마나 유사한지 수치로 적용한 것

$$\text{similarity} = \cos \theta = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$

KoNLPy : 파이썬의 대표적인 한글 형태소 패키지

기존의 C/C++, Java로 잘 만들어진 한글 형태소 엔진을 파이썬 래퍼(Wrapper) 기반으로 재작성한 패키지이다.

기존의 엔진은 그대로 유지한 채 파이썬 기반에서 인터페이스를 제공하기 때문에 검증된 패키지의 안정성을 유지할 수 있다.